

TALLER 1 H2O PRODUCCION

Link Dashboard: <https://datastudio.google.com/reporting/a963b545-7f10-436c-b62a-f9c6f78f2313>

INFORME EJECUTIVO



TALLER 2 - REPORTE DE TOMA DE DESICIONES

1. Interpretación de las Métricas de Negocio

En el contexto de la predicción de fuga de clientes (churn), cada métrica estadística tiene una traducción directa en términos de impacto financiero y operativo. A continuación, se define cada indicador desde la perspectiva del negocio de telecomunicaciones:

Métrica	Definición e Impacto en el Negocio
---------	------------------------------------

Accuracy (Exactitud)	Representa el porcentaje total de predicciones correctas del modelo. En nuestro dataset, modelos como el Dummy Classifier logran 73.15% simplemente prediciendo que ningún cliente se irá, lo que evidencia la trampa del Accuracy en datos desbalanceados: un número alto no garantiza que estemos detectando realmente a los clientes en riesgo. En telecomunicaciones, confiar únicamente en este indicador puede llevar a la dirección a celebrar resultados mientras la base activa de clientes se deteriora sin ser detectada.
Recall (Sensibilidad)	Responde a la pregunta: ¿De todos los clientes que realmente planean cancelar su contrato este período, cuántos logramos identificar antes de que lo hagan? Un Recall bajo implica dejar escapar clientes en riesgo (Falsos Negativos), lo que se traduce en pérdida directa de ingresos recurrentes y un mayor costo de adquisición para reponer esos usuarios. Para campañas de retención proactivas, el Recall determina el alcance real de nuestra capacidad de intervención.
Precision (Precisión)	Responde a: ¿De los clientes que el modelo marca como 'en riesgo de fuga', cuántos realmente tenían intención de cancelar? Una Precision baja genera Falsos Positivos, es decir, invertimos recursos de retención (llamadas, descuentos, meses gratis) en clientes que estaban satisfechos y no pensaban irse. Esto erosiona el margen operativo y hace ineficiente el presupuesto de la campaña.
F1-Score	Es la media armónica entre Precision y Recall, equilibrando ambos indicadores en un único valor. En el contexto gerencial, representa el balance operativo de la campaña: si el F1 es bajo, el modelo está fallando en alguno de los dos frentes, ya sea gastando en clientes incorrectos o perdiendo clientes que no debería dejar escapar. Es el indicador más representativo del rendimiento real en escenarios de datos desbalanceados.
AUC (Área bajo la curva ROC)	Evalúa la capacidad del modelo para discriminar y ordenar correctamente a los clientes según su propensión a cancelar. Un AUC de 0.50 equivale a azar puro (como el Dummy Classifier), mientras que 1.0 sería discriminación perfecta. Los mejores modelos de la tabla alcanzan un AUC de 0.5744, lo que indica una capacidad de ordenamiento moderada pero superior al azar. Este valor guía la calibración de umbrales de decisión para optimizar la campaña.
Kappa y MCC	Cuando los datos están fuertemente desbalanceados (la mayoría de clientes no se va), el Accuracy puede inflar artificialmente la percepción de desempeño del modelo. Kappa y el Coeficiente de Correlación de Matthews (MCC) corrigen esta distorsión evaluando si el modelo supera estadísticamente a una predicción por azar. Son los indicadores más honestos del aprendizaje real: valores de MCC cercanos a 0.2972 en los modelos Gradient Boosting confirman que están capturando patrones genuinos de comportamiento y no simplemente acertando por la distribución de clases.

2. Toma de Decisión Estratégica (Trade-off)

La empresa implementará una campaña de retención donde cada cliente identificado como 'en riesgo de fuga' recibirá un mes de servicio gratuito. Esta decisión implica un costo financiero real y directo, por lo que la elección del modelo determinará la eficiencia del gasto.

2.1 Análisis de Escenarios

Dimensión	Escenario A — Mayor Recall (Decision Tree)	Escenario B — Mayor Precision (CatBoost / LightGBM / XGBoost)
Modelo	Decision Tree Classifier	LightGBM / CatBoost / XGBoost
Recall	0.3567 (mayor de la tabla)	0.1169
Precision	0.3318 (baja)	1.0000 (perfecta)
F1-Score	0.3438 (mayor de la tabla)	0.2094
Implicación financiera	Por cada 100 meses gratis otorgados, aproximadamente 67 irán a clientes que no pensaban cancelar (Falsos Positivos). Gasto masivo e innecesario.	Cada mes gratis otorgado llega exclusivamente a un cliente que realmente estaba a punto de cancelar. Cero desperdicio de incentivos.
Riesgo principal	Fuga de flujo de caja directo por subsidios mal dirigidos	Costo de oportunidad: algunos clientes en riesgo no serán detectados y cancelarán

2.2 Modelo Seleccionado y Justificación Financiera

Decisión ejecutiva: Se selecciona el modelo **Light Gradient Boosting Machine (LightGBM)** para la ejecución de esta campaña de retención.

La justificación se basa en un análisis de costos directos versus costos de oportunidad:

Tipo de Error	Equivalencia Operativa	Impacto Financiero Directo
---------------	------------------------	----------------------------

Falso Positivo	Dar mes gratis a cliente fiel que no iba a cancelar	Pérdida de margen operativo directo e inmediato
Falso Negativo	No detectar al cliente en riesgo que termina cancelando	Pérdida del CLV futuro (Costo de Oportunidad)

Análisis del Decision Tree (Escenario A): Con una Precision de apenas 33.18%, por cada 100 incentivos entregados, 67 llegan a clientes que no tenían ninguna intención de cancelar. En una base de 50,000 clientes, esto representa una fuga de caja masiva y directa que afecta el estado de resultados en el período inmediato. Este error es más costoso porque es visible, inmediato y repetitivo en cada ciclo de campaña.

Ventaja del LightGBM (Escenario B): Con Precision de 1.0000 (100%), cada incentivo entregado impacta únicamente a un cliente que realmente estaba a punto de cancelar. El costo de oportunidad de no detectar a todos los clientes en riesgo (Recall bajo de 0.1169) existe, pero es preferible a un desangre financiero por subsidios masivos mal dirigidos. Adicionalmente, LightGBM registra el mejor AUC (0.5744) de los tres modelos top, se procesa en 15.19 segundos (el más rápido del grupo de alta precisión) y comparte el primer lugar en Accuracy con 76.29%.

En síntesis, para una campaña donde el incentivo tiene un costo unitario elevado y directo, **la Precision es la métrica crítica de negocio**. Gastar bien en menos clientes es financieramente más responsable que gastar mal en muchos. LightGBM optimiza la eficiencia del presupuesto de retención sin sacrificar velocidad ni exactitud general.

3. Escalabilidad de la Infraestructura de TI

La expansión del sistema de predicción de churn desde un piloto de 50,000 registros hacia una plataforma que procese 10 millones de clientes en tiempo real introduce desafíos críticos de arquitectura que van más allá del rendimiento analítico del modelo.

3.1 Problemas de Infraestructura con Algoritmos Pesados

Latencia de Inferencia (SLA Crítico)

Modelos basados en ensambles masivos de árboles como Random Forest o Gradient Boosting Classifier tradicional deben pasar cada registro a través de cientos de árboles de decisión profundos almacenados en memoria RAM. En canales digitales (app móvil, portal web, CRM en tiempo real), el modelo debe puntuar a cada cliente en milisegundos. Con Random Forest procesando 10 millones de registros, la latencia acumulada supera los límites tolerables para la experiencia del usuario y los acuerdos de nivel de servicio (SLA) internos.

Costos de Cómputo Elástico en la Nube

El procesamiento de 10 millones de clientes diarios con modelos pesados obliga a aprovisionar clusters de cómputo con instancias de alta memoria y CPU (tipo c5 o m5 en AWS, equivalentes en Azure). Comparando los tiempos de la tabla, el Gradient Boosting Classifier tradicional tarda 28.41 segundos frente a los 15.19 segundos de LightGBM, casi el doble, manteniendo métricas de negocio iguales o inferiores. Extra Trees Classifier alcanza 28.60 segundos entregando un Accuracy de apenas 70.32% y Precision de 40.67%, un resultado operativamente inaceptable para su costo computacional.

Consumo de Memoria RAM y Almacenamiento

Los ensambles tradicionales requieren serializar y cargar en memoria cientos o miles de árboles individuales. En arquitecturas serverless o de microservicios, cada instancia cargada tiene un límite de memoria, lo que fuerza a usar instancias sobredimensionadas o a implementar esquemas de particionamiento complejos que incrementan el costo operativo mensual y la complejidad de mantenimiento del sistema.

3.2 Justificación Arquitectónica ¿Vale un 2% Más de Accuracy?

Regla de oro de Arquitectura de Sistemas de Información: Un incremento marginal en el rendimiento analítico no puede justificar un crecimiento exponencial en el costo de infraestructura.

Analizando la tabla de resultados, la diferencia entre el mejor modelo (76.29% Accuracy, LightGBM) y un modelo complejo como Extra Trees (70.32%) o Random Forest (72.09%) no representa únicamente una diferencia técnica: representa una ecuación financiera de retorno sobre inversión en infraestructura tecnológica.

Criterio	Modelos Pesados (Random Forest / Extra Trees)	LightGBM (Modelo Seleccionado)
Tiempo de Procesamiento	28+ segundos (doble o más)	15.19 segundos
Accuracy de Negocio	70–72% (inferior)	76.29% (máximo de la tabla)
Precision de Negocio	40–45% (ineficiente)	100% (perfecta)
Costo de Nube Estimado	Multiplicado por 2–10x en cómputo	Arquitectura serverless liviana posible

Arquitectura Viable	Clusters dedicados obligatorios	Microservicios / Serverless (AWS Lambda, Azure Functions)
----------------------------	---------------------------------	---

Desde la perspectiva de Sistemas de Información Gerencial, **la respuesta es categóricamente no:** no se justifica multiplicar el costo de servidores por un incremento marginal o nulo en el rendimiento analítico. LightGBM fue diseñado específicamente con algoritmos basados en histogramas que reducen drásticamente el consumo de memoria y CPU, manteniendo el mismo nivel de exactitud que los ensambles más costosos.

La arquitectura recomendada para los 10 millones de clientes diarios es un pipeline serverless en AWS Lambda o Azure Functions con el modelo LightGBM serializado, procesando lotes incrementales durante las horas de menor tráfico y ejecutando predicciones en tiempo real para eventos de alto valor (contacto con soporte, vencimiento de contrato). Este diseño garantiza que cada dólar invertido en infraestructura genere un retorno directo en la retención de ingresos, sin sacrificar rendimiento de negocio ni escalabilidad operativa.

Conclusión Ejecutiva

El análisis integral de métricas, trade-offs financieros y consideraciones de infraestructura converge en una decisión unificada: [object Object] en el estado actual del sistema.

- Maximiza la Precision (100%), protegiendo el flujo de caja de campañas de retención con incentivos de alto costo unitario.
- Registra el mejor AUC (0.5744) entre los modelos de alta precisión, ofreciendo la mayor capacidad de discriminación del ecosistema.
- Comparte el primer lugar en Accuracy (76.29%) con CatBoost y XGBoost, sin sacrificio en exactitud general.
- Procesa en 15.19 segundos, siendo el más eficiente del grupo líder y habilitando arquitecturas serverless de bajo costo en la nube.
- Permite escalar a 10 millones de registros diarios sin multiplicar los costos de infraestructura, alineando la inversión en TI con el retorno financiero del negocio.

La implementación de este sistema de información debe ir acompañada de un proceso de mejora continua: re-entrenamiento periódico del modelo con nuevos datos de comportamiento, monitoreo activo del drift de las métricas en producción, y revisión trimestral del umbral de decisión en función del costo actualizado de los incentivos de retención.

Bibliografía

(2026). Procesamiento y evaluación de modelos de Machine Learning para la predicción de fuga de clientes (Churn) [Cuaderno de Google Colab]. Recuperado el 17 de mayo de 2026.